Mustererkennung Übung 5

Benjamin Kiesling, Peewee Manzer

1. Aufgabe (5 Punkte): Lineare Regression

Importieren Sie den Datensatz fish.txt in matlab. Das Format ist: index ; the age of the fish ; the water temperature in degrees Celsius ; the length of the fish

a. (3 Punkte)

Schätzen Sie den Wert für "length" anhand der Parameter "age" und "temperature" mit linearer Regression. Visualisieren Sie dreidimensional die tatsächlichen Datenpunkte, die geschätzten Datenpunkte, sowie die Abstände der tatsächlichen zu den geschätzten Datenpunkten.

```
In [1]: %matplotlib inline
    import matplotlib.pyplot as plt
    import pandas as pd
    import numpy as np
    from mpl_toolkits.mplot3d import Axes3D
# make plots bigger

plt.rcParams['figure.figsize'] = 16, 16
```

Out[2]:

	fish age	water temperature	fish length
1	14	25	620
2	28	25	1315
3	41	25	2120
4	55	25	2600
5	69	25	3110

```
In [3]: from sklearn.linear_model import LinearRegression

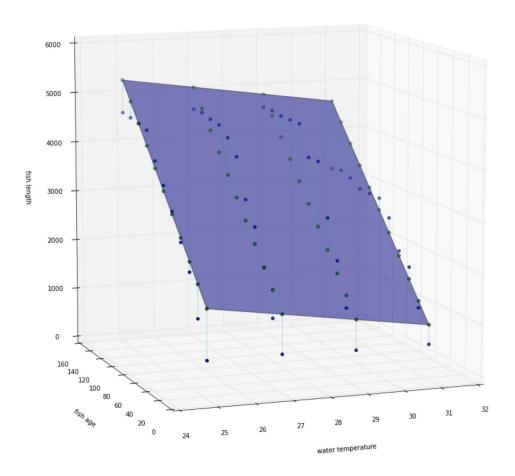
y = fishData['fish length']
features = ['water temperature','fish age']
x = fishData[features]
lm = LinearRegression()
lm.fit(x,y)

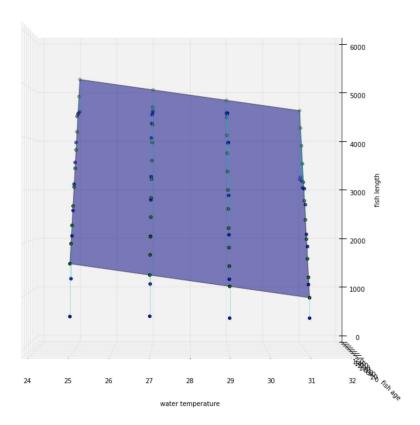
print lm.intercept_
print lm.coef_
zip(features, lm.coef_)

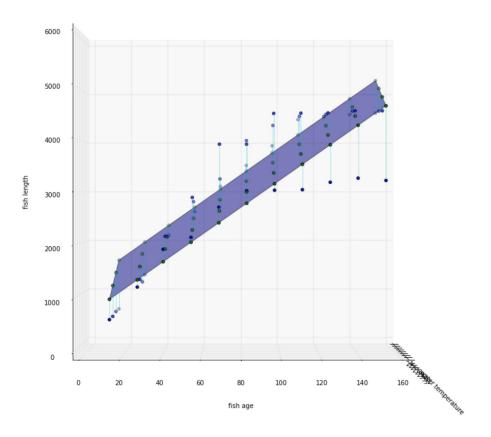
3904.26601675
[-106.41363636 26.24068177]
Out[3]: [('water temperature', -106.41363636363634), ('fish age', 26.240681765825098)]
```

b. (2 Punkte) Visualisieren Sie die durch die in Aufgabe a) berechneten Koeffizienten definierte Ebene.

```
In [4]: x = list(fishData['water temperature'])
        y = list(fishData['fish age'])
        z = list(fishData['fish length'])
        x min = fishData['water temperature'].min()
        x max = fishData['water temperature'].max()
        y min = fishData['fish age'].min()
        y max = fishData['fish age'].max()
        x_range = np.array([x_min,x_max])
        y range = np.array([y min,y max])
        x_surf, y_surf = np.meshgrid(x_range, y_range)
        lr_plane = lm.intercept_+lm.coef_[0]*x_surf+lm.coef_[1]*y_surf
        def plot fig(fignb,azim,elev):
            fig = plt.figure(fignb)
            ax = fig.add subplot(111, projection='3d',azim = azim,elev = elev)
            ax.scatter(x,y,z)
            ax.plot surface(x surf,
                             y surf,
                            lr plane.reshape((2, 2)),
                            alpha=.5)
            ax.set_xlabel('water temperature')
            ax.set_ylabel('fish age')
            ax.set_zlabel('fish length')
            z_i_hat = lm.intercept_+np.multiply(lm.coef_[0],x)+np.multiply(lm.coef_[1],y
            ax.scatter(x,y,z_i_hat,c='g')
            for i, z_i in enumerate(z):
                ax.plot([x[i],x[i]],[y[i],y[i]],[z[i],z_i_hat[i]], c='c',alpha = .35)
        plot_fig(0,-110,10)
        plot_fig(1,-90,0)
        plot_fig(2,0,0)
        plt.show()
```







2. Aufgabe (5 Punkte): Subset Selection

Importieren Sie den Datensatz winequalityred. txt in matlab. Das Format ist: fixed acidity; volatile acidity; citric acid; residual sugar; chlorides; free sulfur dioxide; total sulfur dioxide; density; pH; sulphates; alcohol; quality (score between 0 and 10) Schätzen Sie den Wert für "quality" mit linearer Regression anhand aller möglichen Kombinationen der anderen Parameter (also jeweils für alle Einer, Zweier, Dreierkombinationen, usw.) und berechnen jeweils die Summe der quadratischen Abweichungen zwischen den geschätzten und tatsächlichen Werten für "quality". Visualisieren Sie dies als zweidimensionalen Plot. Auf der xAchse steht dabei die Anzahl der verwendeten Parameter, auf der yAchse die Summe der quadratischen Abweichungen (für alle Kombinationen der jeweiligen Anzahl der Parameter) .

(1599, 12)

Out[5]:

	fixed_acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	рН	sulphates	alcol
0	7.4	0.70	0.00	1.9	0.076	11	34	0.9978	3.51	0.56	9.4
1	7.8	0.88	0.00	2.6	0.098	25	67	0.9968	3.20	0.68	9.8
2	7.8	0.76	0.04	2.3	0.092	15	54	0.9970	3.26	0.65	9.8
3	11.2	0.28	0.56	1.9	0.075	17	60	0.9980	3.16	0.58	9.8
4	7.4	0.70	0.00	1.9	0.076	11	34	0.9978	3.51	0.56	9.4

```
In [6]: from sklearn.linear_model import LinearRegression
        from sklearn.metrics import mean_squared_error as mse
        def linregCombi(features):
            x = wineData[features]
            y = wineData['quality']
            lm = LinearRegression()
            lm.fit(x,y)
            featData = {}
            for feat in features:
                featData[feat] = wineData[feat]
            X new = pd.DataFrame(featData)
            #pred = lm.predict(X new)
            pred = lm.intercept
            feat = zip(features, lm.coef)
            for f in feat:
                pred +=f[1] *wineData[f[0]]
            return np.sum(np.square(y-pred)) #mse(y,pred) or np.sum(np.square(y-preds))
        for SSD
```

```
In [7]: import itertools

features = ['fixed_acidity', 'volatile acidity', 'citric acid', 'residual sugar'
    , 'chlorides', 'free sulfur dioxide', 'total sulfur dioxide', 'density', 'pH', '
    sulphates', 'alcohol',]

fig = plt.figure()
    ax = fig.add_subplot(111)
    for L in range(1,len(features)+1):
        for fsubset in itertools.combinations(features,L):
            tmp = linregCombi(list(fsubset))
            ax.scatter(L,tmp,alpha = .4)
    plt.axis('auto')
    plt.xticks(np.arange(12))
    plt.show()
```

